VAN模型自验报告

> 邢朝龙 kaierlong@126.com

1. 模型简介

1.1 网络模型结构简介

`Visual Attention Network（VAN）`是2022年提出的视觉领域的网络结构。

传统的将NLP领域的self-attention应用于2D图像时，会面临三个问题：

- 将图像处理为一维序列，忽略了其2D结构
- 二次复杂度对于高分辨率的图像来说，计算量剧增
- 只捕捉了空间适应性，而忽略了通道适应性

针对以上问题，论文提出适用于视觉任务的`large kernel attention（LKA）`。

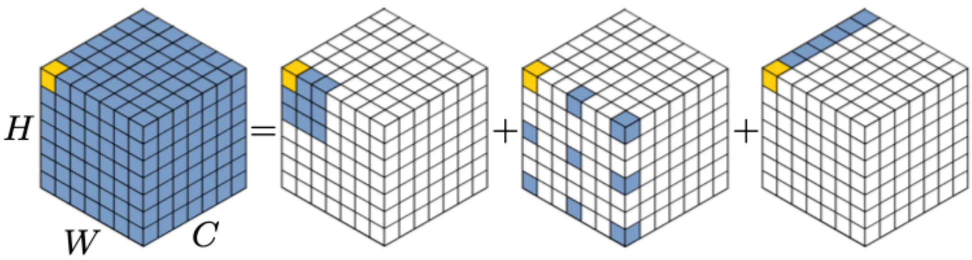

Fig. 2. Decomposition diagram of large-kernel convolution. A standard convolution can be decomposed into three parts: a depth-wise convolution (DW-Conv), a depth-wise dilation convolution (DW-D-Conv), and a pointwise convolution (1×1 Conv). The colored grids represent the location of convolution kernel and the yellow grid means the center point. The diagram shows that a 13×13 convolution is decomposed into a 5×5 depth-wise convolution, a 5×5 depth-wise dilation convolution with dilation rate 3, and a pointwise convolution. Note: zero paddings are omitted in the above figure.

图1

如图1，一个大尺寸的卷积可以分成三部分：

- 空间上的局部卷积（depth-wise convolution）
- 空间上的long-range convolution （depth-wise dilation convolution）
- 通道上的卷积 （1x1 convolution）

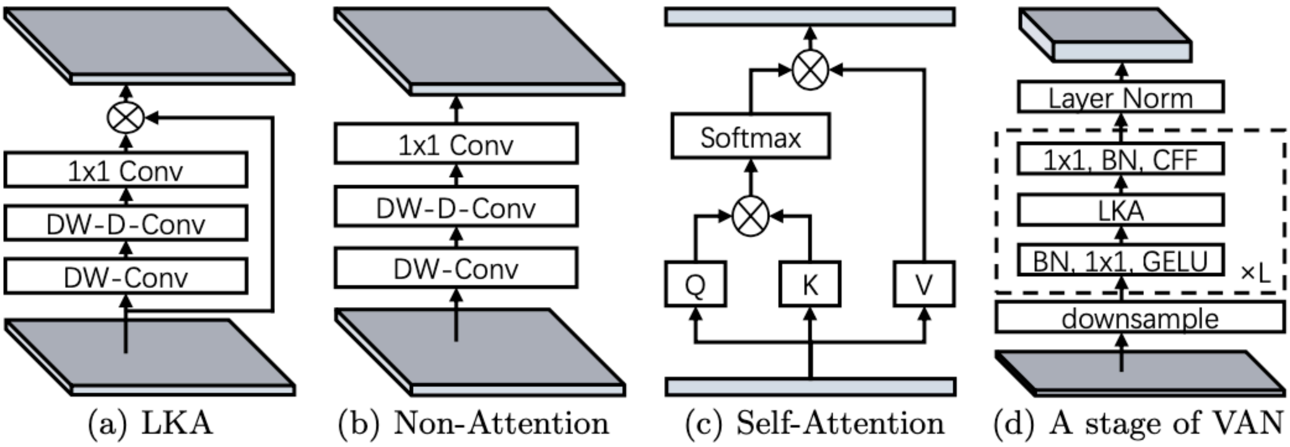

Fig. 3. The structure of different modules: (a) the proposed Large Kernel Attention (LKA); (b) non-attention module; (c) the self-attention module [80]; (d) a stage of our Visual Attention Network (VAN). CFF means convolutional feed-forward network. Residual connection [31] is omitted in (d). The difference between (a) and (b) is the element-wise multiply. It is worth noting that (c) is designed for 1D sequences.

图2

拆分后的卷积可以捕捉长距离信息，并且节省计算资源，得到长距离关系后，能够估计每个点的重要程度，生成attention map，如图二所示。

最终，LKA的数学表达如下图3所示。

$$\begin{aligned} Attention &= \mathrm{Conv}_{1\times 1}(\text{DW-D-Conv}(\text{DW-Conv}(\mathrm{F}))), \\ Output &= Attention \otimes F. \end{aligned}$$

图3

VAN 结构简单，有四层，不同量级的模型结构如下图4所示，本文所选模型结构为红色标记部分。

Table 2. The detailed setting for different versions of the VAN. e.r. represents expansion ratio in the feed-forward network.

stage	output size	e.r.	VAN-Tiny	VAN-Small	VAN-Base	VAN-Large	VAN-Huge
1	$\frac{H}{4} \times \frac{W}{4} \times C$	8	$C = 32$ $L = 3$	$C = 64$ $L = 2$	$C = 64$ $L = 3$	$C = 64$ $L = 3$	$C = 64$ $L = 3$
2	$\frac{H}{8} \times \frac{W}{8} \times C$	8	$C = 64$ $L = 3$	$C = 128$ $L = 2$	$C = 128$ $L = 3$	$C = 128$ $L = 5$	$C = 128$ $L = 6$
3	$\frac{H}{16} \times \frac{W}{16} \times C$	4	$C = 160$ $L = 5$	$C = 320$ $L = 4$	$C = 320$ $L = 12$	$C = 320$ $L = 27$	$C = 320$ $L = 40$
4	$\frac{H}{32} \times \frac{W}{32} \times C$	4	$C = 256$ $L = 2$	$C = 512$ $L = 2$	$C = 512$ $L = 3$	$C = 512$ $L = 3$	$C = 512$ $L = 3$
Parameters (M)			4.1	13.9	26.6	44.8	60.3
FLOPs (G)			0.9	2.5	5.0	9.0	12.2

1.2 数据集

使用训练及测试数据集如下：

```
使用的数据集：ImageNet2012

数据集大小：共1000个类、224*224彩色图像
训练集：共1,281,167张图像
测试集：共50,000张图像
数据格式：JPEG
注：数据在dataset.py中处理。
下载数据集，目录结构如下：
└─dataset
    ├─train                 # 训练数据集
    └─val                   # 评估数据集
```

1.3 代码提交地址

暂时提交在启智中，私有未开源。

仓库地址如下：https://git.openi.org.cn/kaierlong/VAN-Classification.git

2. 代码目录结构说明

代码目录结构及说明如下：

```
.
├── eval.py         // 评估文件
├── image         // 文档图片目录
├── LICENSE
├── README_CN.md         // 中文说明文档
├── README.md         // 说明文档
├── src
│   ├── args.py
│   ├── configs         // 超参数配置目录
│   │   ├── parser.py
│   │   ├── van_base_224.yaml
│   │   ├── van_large_224.yaml
│   │   ├── van_small_224.yaml
│   │   └── van_tiny_224.yaml
│   ├── data         // 数据加载及处理目录
│   │   ├── augment
│   │   │   ├── auto_augment.py
│   │   │   ├── __init__.py
│   │   │   ├── mixup.py
```

```
│   │   │   └── random_erasing.py
│   │   ├── data_utils
│   │   │   ├── __init__.py
│   │   │   └── moxing_adapter.py
│   │   ├── imagenet.py
│   │   └── __init__.py
│   ├── models        // 模型目录
│   │   ├── __init__.py
│   │   └── van
│   │       ├── get_van.py
│   │       ├── __init__.py
│   │       ├── misc.py
│   │       └── van.py        // vand定义文件
│   ├── tools        // 相关工具目录
│   │   ├── callback.py
│   │   ├── cell.py
│   │   ├── criterion.py
│   │   ├── get_misc.py
│   │   ├── __init__.py
│   │   ├── optimizer.py
│   │   └── schedulers.py
│   └── trainers        // 训练优化目录
│       ├── __init__.py
│       └── train_one_step_with_scale_and_clip_global_norm.py
└── train.py        // 训练文件
```

3. 自验结果（交付精度规格时需要补齐）

3.1 自验环境

软硬件环境如下：

- 启智AI引擎：MindSpore-1.5.1-c79-python3.7-euleros2.8-aarch64
- Ascend: 8 * Ascend-910(32GB) | ARM: 192 核 2048GB

详细环境配置参见下图：

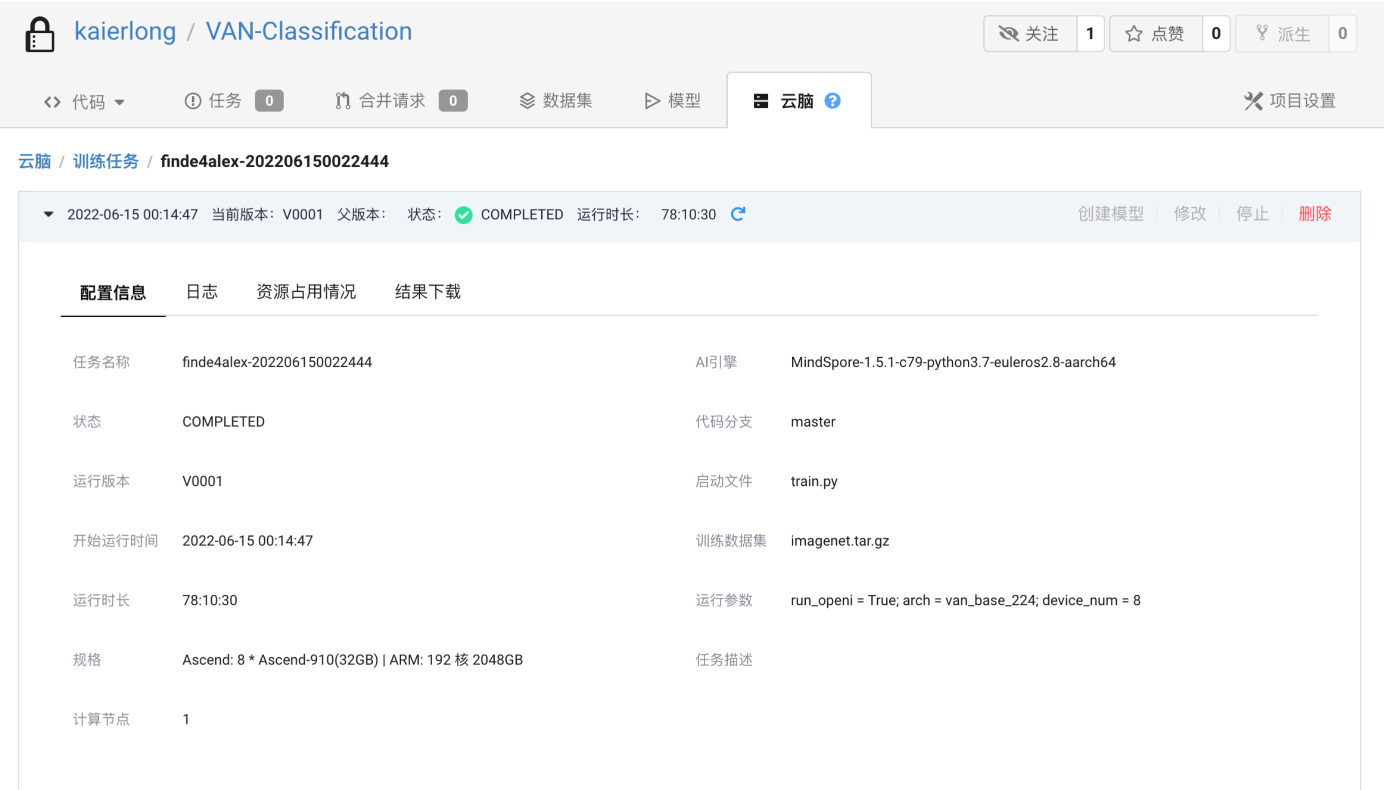

3.2 训练超参数

超参数配置如下：

> 其中data_url由启智平台实际数据地址替换，训练时替换。

```yaml
# Architecture
arch: van_base_224

# ===== Dataset ===== #
data_url: ./data/imagenet
set: ImageNet
num_classes: 1000
mix_up: 0.8
cutmix: 1.0
auto_augment: rand-m9-mstd0.5-inc1
interpolation: bicubic
re_prob: 0.0
re_mode: pixel
re_count: 1
mixup_prob: 1.
switch_prob: 0.5
mixup_mode: batch
crop_ratio: 0.9

# ===== Learning Rate Policy ======== #
optimizer: adamw
```

```yaml
lr_scheduler: cosine_lr
base_lr: 0.0005
min_lr: 0.000001
warmup_lr:  0.000001
warmup_length: 5
cool_length: 10
cool_lr: 0.000001


# ===== Network training config ===== #
amp_level: O1
keep_bn_fp32: True
beta: [ 0.9, 0.999 ]
clip_global_norm_value: 10.
is_dynamic_loss_scale: True
epochs: 310
label_smoothing: 0.1
loss_scale: 1024
weight_decay: 0.05
momentum: 0.9
batch_size: 128

# ===== Hardware setup ===== #
num_parallel_workers: 32
device_target: Ascend

# ===== Model config ===== #
drop_path_rate: 0.2
embed_dims: [64, 128, 320, 512]
mlp_ratios: [8, 8, 4, 4]
depths: [3, 3, 12, 3]
num_stages: 4
image_size: 224
```

3.3 训练

3.3.1 如何启动训练脚本

训练如何启动：

- 启智平台

模型训练在启智平台完成，完整训练配置如下图所示：

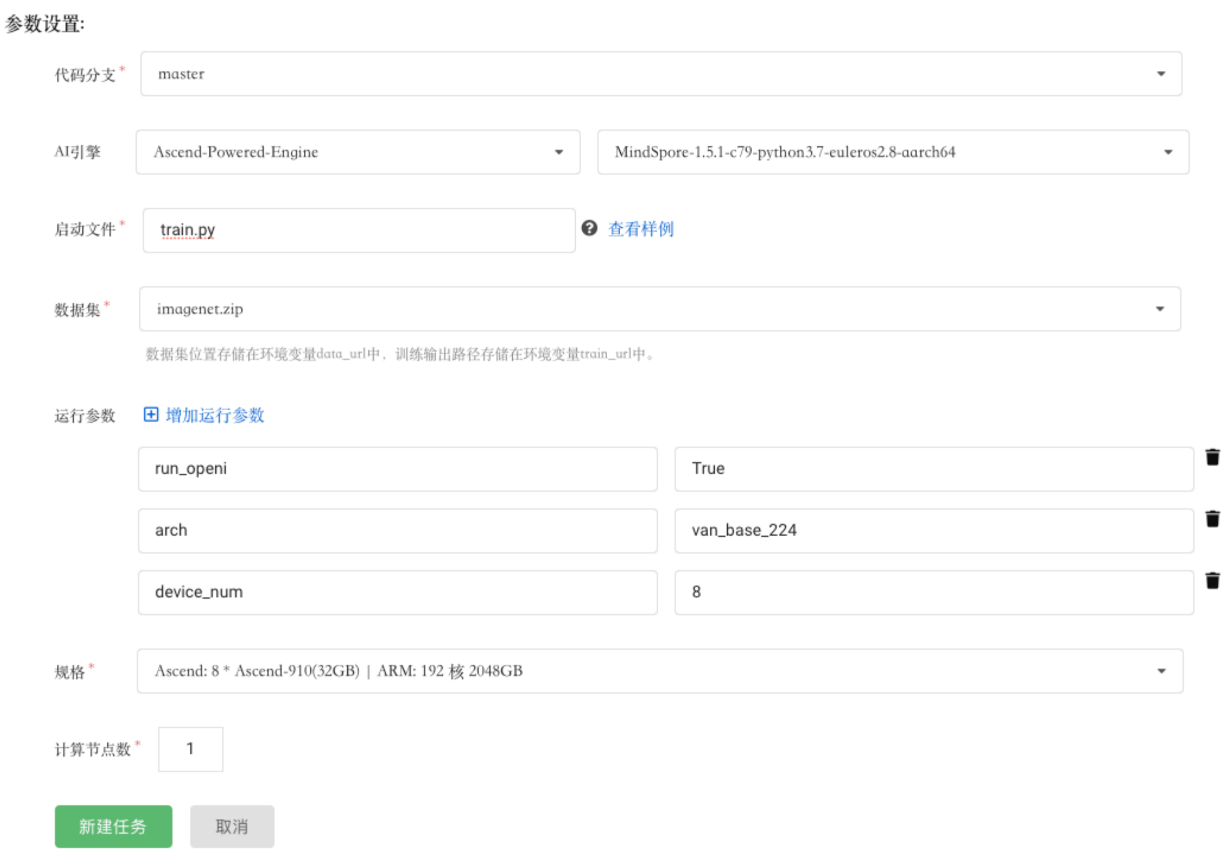

- 本地命令

如果需要本地训练，可以使用如下命令：

```
python3 train.py --run_openi=True --arch=van_base_224 --dataset_sink_mode=False --device_num=8
```

3.3.2 训练精度结果

- 论文精度如下:

2. VAN Models

Model	#Params(M)	GFLOPs	Top1 Acc(%)	Download
VAN-Tiny	4.1	0.9	75.4	Google Drive, Tsinghua Cloud, Hugging Face 🤗
VAN-Small	13.9	2.5	81.1	Google Drive, Tsinghua Cloud, Hugging Face 🤗
VAN-Base	26.6	5.0	82.8	Google Drive, Tsinghua Cloud,Hugging Face 🤗,
VAN-Large	44.8	9.0	83.9	Google Drive, Tsinghua Cloud, Hugging Face 🤗
VAN-Huge	TODO	TODO	TODO	TODO

Unofficial keras (tensorflow) version.

- 复现精度如下：

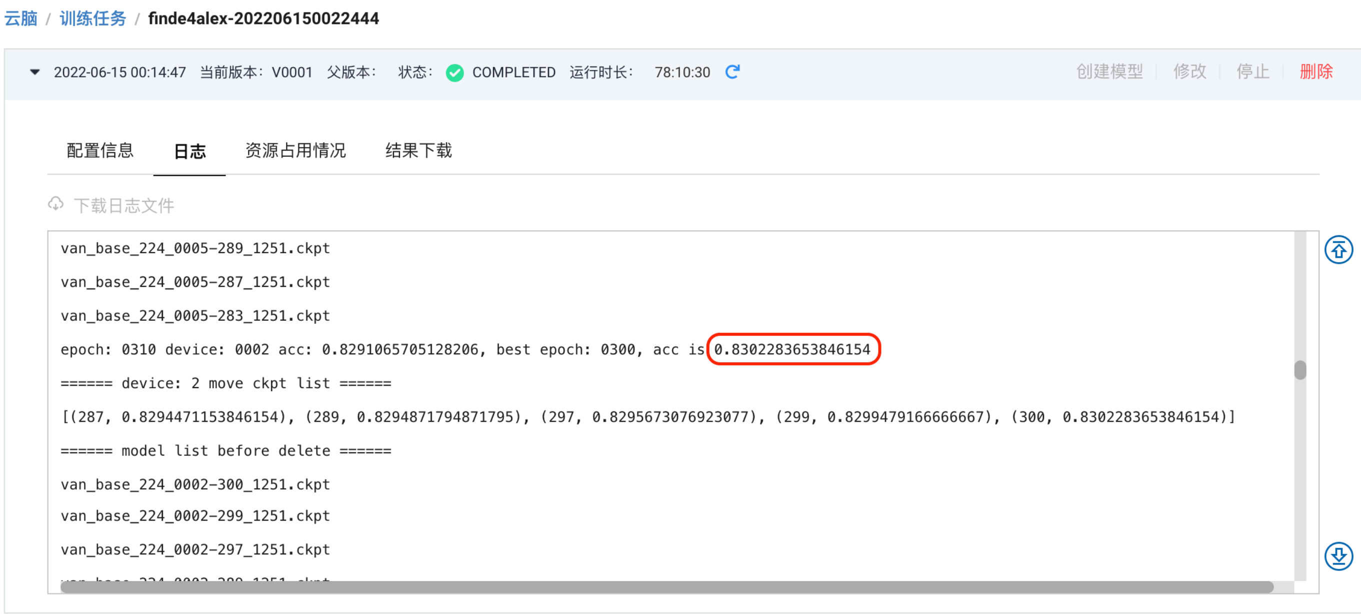

- 精度结果对比
  - 论文精度为：82.8
  - 复现精度为：83.02（最优值）
  - 比论文还要好0.202个绝对百分点，相对提升0.26%

```
83.02 - 82.8 = 0.202
(83.02 - 82.8) / 82.8 * 100 = 0.2657
```

3.4 模型推理

推理命令如下：

```
python3 eval.py --config=src/configs/van_base_224.yaml --pretrained={ckpt_path} --device_id={device_id} --device_target={device_target} --data_url={data_url}
```

4. 参考资料

4.1 参考论文

- [2202.09741] Visual Attention Network (arxiv.org)

4.2 参考git项目

- [Visual-Attention-Network/VAN-Classification (github.com)]

4.3 参考文献

- 【Attention】Visual Attention Network_呆呆的猫的博客-CSDN博客
- 【ARXIV2202】Visual Attention Network - 知乎 (zhihu.com)